

## 1. 阅读作业 (\*10%)

在本次课程中，你学习了 VC 维这个概念。“对于非线性分类器，VC 维非常难于计算，在学术研究领域，这仍然是一个有待回答的开放性问题。但对于线性分类器，VC 维是可以计算的。”请你阅读下面博文中

<http://blog.csdn.net/baimafujinji/article/details/44856089>

的第二部分“VC 维”，以了解对于一个线性分类器，我们该如何计算其 VC 维，特别注意“Points in General Position 和 Shatter”这两个概念。提交一张你阅读的界面截图。

另外，你还需要阅读如下博文中的关于 NFL 原理的部分（注意：你只需要阅读文章中的第一部分暨 NFL 原理的部分）

<http://blog.csdn.net/baimafujinji/article/details/6475824>

提交一张你阅读的界面截图。同时，请你思考一下，NFL 原理和我们讲的 VC 维有什么相通的地方或者有什么联系，用两三句话简单总结一下你的认识或者理解。

你不需要回答，但请你仔细思考一下文章最后给出的结论： $d$  维空间中的线性分类器之 VC 维等于  $d+1$ ，如果你自己能够理解清楚这背后的道理，说明你对 VC 维的理解已经足够深入了！

学习是自己的事情，请认真理解其中内容，切勿只截图而不阅读。

**二、VC维**

对于一个给定的分类器或者Hypothesis，还如何确定VC维呢？一个不好的消息是，对于非线性分类器，VC维非常难于计算，在学术研究领域，这仍然是一个有待回答的开放性问题。一个好消息是，对于线性分类器，VC维是可以计算的，所以下面我们主要讨论线性分类器的VC维。但在此之前，我们还需要先了解两个关键概念，即Points in General Position和Shatter。

在一个 $n$ 维特征空间中，一个包含 $m$ 个点的集合 ( $m > n$ ) is in general position 当且仅当没有包含 $n+1$ 个点的子集落在 $n-1$ 维的超平面上。

来看两个具体的例子，如下图所示，在一个二维空间中，有4个点，显然其中不存在包含3个点的子集都落在一个1维的超平面上的情况，所以说这些点都是in general position。

但是下图中的情况则不然，我们额外引入一个点后，显然存在三个点都落在一条直线上的情况，所以这5个点，就不是in general position的。（当然，即使是上面有4个点的图，如果其中有3个点共线，它们也不是in general position的。）

加入CSDN，享受更精准的内容推荐，与500万程序员共同成长！

登录 注册



## 2. 编程实践题 (\*20%)

在之前的作业中我们已经给出了 countries\_data 数据，现在请你利用此数据建立最大间隔分类器（也就是 SVM 模型）来对两类国家进行分类。具体要求如下：

- 1) 使用 MATLAB, Python 或者 R。
- 2) 通过代码读入一个 csv 文件的方式来导入数据。
- 3) 评估你的分类器（使用 Accuracy、Precision、Recall 和 F1-Score）。
- 4) 用图形化的方式展示你的分类结果。

```
(env-cpu) testuser@testuser-System-Product-Name:~/Documents/jupyter/dataguru/ml_zuofei$ python lecture_05_hn_scikit-learn.py
None
      precision    recall  f1-score   support

     0       1.00      1.00      1.00        15
     1       1.00      1.00      1.00        15
 avg / total       1.00      1.00      1.00        30

[[15  0]
 [ 0 15]]
      precision    recall  f1-score   support

     0       0.88      0.93      0.90        15
     1       0.93      0.87      0.90        15
 avg / total       0.90      0.90      0.90        30





[[14  1]
 [ 2 13]]
      precision    recall  f1-score   support

     0       1.00      1.00      1.00        15
     1       1.00      1.00      1.00        15
 avg / total       1.00      1.00      1.00        30

[[15  0]
 [ 0 15]]
      precision    recall  f1-score   support

     0       1.00      1.00      1.00        15
     1       1.00      1.00      1.00        15
 avg / total       1.00      1.00      1.00        30

[[15  0]
 [ 0 15]]
█
```



代码

```
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd
```

```

from sklearn import metrics, svm

def extract_data(filename):
    df = pd.read_csv(filename)
    df_fvecs = df[['Services_of_GDP', 'ages65_of_total']]
    fvecs = df_fvecs.as_matrix()
    labels = df[['label']].as_matrix()
    labels = labels.reshape(1, labels.size).flatten()
    return fvecs, labels

def make_meshgrid(x, y, h=.02):
    x_min, x_max = x.min() - 1, x.max() + 1
    y_min, y_max = y.min() - 1, y.max() + 1
    xx, yy = np.meshgrid(np.arange(x_min, x_max, h),
                          np.arange(y_min, y_max, h))

    return xx, yy

def plot_contours(ax, clf, xx, yy, **params):
    Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])
    Z = Z.reshape(xx.shape)
    out = ax.contourf(xx, yy, Z, **params)
    return out

X, y = extract_data('countries_data.csv')

C = 1.0
models = (svm.SVC(kernel='linear', C=C),
          svm.LinearSVC(C=C),
          svm.SVC(kernel='rbf', gamma=0.7, C=C),
          svm.SVC(kernel='poly', degree=3, C=C))

for clf in models:
    clf.fit(X, y)
    # metrics
    predicted = clf.predict(X)
    print(metrics.classification_report(y, predicted))
    print(metrics.confusion_matrix(y, predicted))

titles = ('SVC with linear kernel',
          'LinearSVC (linear kernel)',
          'SVC with RBF kernel',

```

'SVC with polynomial (degree 3) kernel')

```
fig, sub = plt.subplots(2, 2)
plt.subplots_adjust(wspace=0.4, hspace=0.4)

X0, X1 = X[:, 0], X[:, 1]
xx, yy = make_meshgrid(X0, X1)

for clf, title, ax in zip(models, titles, sub.flatten()):
    plot_contours(ax, clf, xx, yy, cmap=plt.cm.coolwarm, alpha=0.8)
    ax.scatter(X0, X1, c=y, cmap=plt.cm.coolwarm, s=20,
edgecolors='k')
    ax.set_xlim(xx.min(), xx.max())
    ax.set_ylim(yy.min(), yy.max())
    ax.set_xlabel('Sepal length')
    ax.set_ylabel('Sepal width')
    ax.set_xticks(())
    ax.set_yticks(())
    ax.set_title(title)

plt.show()
```

### 3. 数学推导题 (\*35%)

推导 PPT 中第 24 页最下方的等式：

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^k \alpha_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1] = \sum_{i=1}^k \alpha_i - \frac{1}{2} \sum_{i,j=1}^k \alpha_i \alpha_j y_i y_j (x_i)^T x_j$$

提交完整的证明过程。答案会随下次课程资料一同公布。

$$\begin{aligned}
L(w, b, a) &= \frac{1}{2} \|w\|^2 - \sum_{i=1}^k a_i [y_i (w^T x_i + b) - 1] \\
&= \frac{1}{2} \|w\|^2 - \sum_{i=1}^k (a_i y_i w^T x_i + a_i y_i b - a_i) \\
&= \frac{1}{2} \|w\|^2 - w^T \sum_{i=1}^k (a_i y_i x_i) - \sum_{i=1}^k (a_i y_i b) + \sum_{i=1}^k a_i \\
&= \frac{1}{2} \|w\|^2 - w^T w - b \sum_{i=1}^k (a_i y_i) + \sum_{i=1}^k a_i \\
&= \frac{1}{2} \|w\|^2 - w^2 - b \cdot 0 + \sum_{i=1}^k a_i \\
&= -\frac{1}{2} \|w\|^2 + \sum_{i=1}^k a_i \\
&= \sum_{i=1}^k a_i - \frac{1}{2} \|w\|^2 \\
&= \sum_{i=1}^k a_i - \frac{1}{2} \sum_{i=1}^k (a_i y_i x_i) \cdot \sum_{j=1}^k (a_j y_j x_j) \\
&= \sum_{i=1}^k a_i - \frac{1}{2} \sum_{i=1}^k \sum_{j=1}^k (a_i a_j y_i y_j x_i x_j)
\end{aligned}$$

#### 4. 证明题 (\*35%)

对于带等式约束的优化问题，我们可以使用“拉格朗日乘数法”。拉格朗日乘数法在机器学习（甚至图像处理）中都有较多应用，例如 SVM 中的凸优化、回归分析中的正则化、以及最大熵模型的推导。

为了强化你对拉格朗日乘数法的理解，最后这个问题可以帮助你亲身体验一下它的应用。请你运用拉格朗日乘数法来证明几何-算术均值不等式。注意：这个不等式的证明方法很多，本题的意思是要求你仅仅使用拉格朗日乘数法来证明之，如果你采用其它方法，则会被判定为“答非所问”。

几何均值不等式：

for any list of  $n$  nonnegative real numbers  $x_1, x_2, \dots, x_n$ , we have

$$\frac{x_1 + x_2 + \dots + x_n}{n} \geq \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n},$$

and that equality holds if and only if  $x_1 = x_2 = \dots = x_n$ .

关于这个不等式的更多内容，你还可以参考（如果你有兴趣的话）：

[https://en.wikipedia.org/wiki/Inequality\\_of\\_arithmetic\\_and\\_geometric\\_means](https://en.wikipedia.org/wiki/Inequality_of_arithmetic_and_geometric_means)

$$\begin{aligned}
 &AM \text{ arithmetic } \frac{x_1 + x_2 + \dots + x_n}{n} \\
 &GM \text{ geometric } \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n} \\
 &AM \geq GM \\
 &\text{设 } f(x_1, x_2, \dots, x_n) = (x_1 \cdot x_2 \cdot \dots \cdot x_n)^{\frac{1}{n}} \\
 &g(x_1, x_2, \dots, x_n) = \frac{x_1 + x_2 + \dots + x_n}{n} = C
 \end{aligned}$$

$$\begin{aligned}
 &\nabla f = \lambda \nabla g \\
 &\left(\frac{1}{n}, \frac{1}{n}, \dots, \frac{1}{n}\right) = \left(\frac{\partial}{\partial x_1} (x_1^{\frac{1}{n}} (x_2 \dots x_n)^{\frac{1}{n}}), \dots, \frac{\partial}{\partial x_n} (x_1^{\frac{1}{n}} (x_2 \dots x_n)^{\frac{1}{n}})\right) \\
 &= \left(\frac{1}{n} (x_1^{\frac{1}{n}-1} (x_2 \dots x_n)^{\frac{1}{n}}), \dots, \frac{1}{n} (x_1^{\frac{1}{n}} (x_2 \dots x_n)^{\frac{1}{n}-1})\right) \\
 &\text{得: } \frac{1}{n} = \frac{1}{n} (x_1^{\frac{1}{n}-1} (x_2 \dots x_n)^{\frac{1}{n}}) \\
 &\quad \frac{1}{n} = \frac{1}{n} (x_2^{\frac{1}{n}-1} (x_1 x_3 \dots x_n)^{\frac{1}{n}}) \\
 &\quad \vdots \\
 &\quad x_i = (x_1 \dots x_n)^{\frac{1}{n}} \\
 &\text{对 } f(x) \text{ 最大值时 } f(x) \leq C, g(x) \\
 &\text{对其他值时 } f(x) \leq g(x) \\
 &\text{即 } GM \leq AM
 \end{aligned}$$

\* 难度系数及所占比例